





PRÁCTICA INFORMÁTICA

Visualización y Análisis de Datos

Sergio Gil López

ENUNCIADO

El objetivo de la evaluación es la creación de una visualización utilizando la librería para visualización de Python Altair (<https://altair-viz.github.io/>). El equipo docente proporcionará en la plataforma virtual del curso académico diversos recursos y tutoriales para facilitar el aprendizaje de uso.

La visualización debe seguir los principios de diseño vistos y puede elaborarse o bien sobre una fuente de datos que el estudiante considere de su interés o bien usar el dataset sugerido por el equipo docente.

EJERCICIO PROPUESTO

1. Objetivos

Objetivo Global

Analizar la oferta de alojamiento vacacional en diferentes mercados turísticos de España (Toledo, San Sebastián, Valencia y Málaga) mediante técnicas avanzadas de visualización de datos, con el fin de identificar patrones de precios dinámicos basados en la antelación de reserva (*days_ahead*), la ocupación (*guests*), la ubicación geoespacial y las características estructurales de los inmuebles.

Objetivos Secundarios

Mapear la oferta de alojamientos, utilizando las coordenadas interceptadas del tráfico de red, para visualizar la saturación espacial y evaluar la correlación entre la prima de precio y la distancia kilométrica al centro histórico.

Comparar la variación del precio en función de la antelación temporal de la reserva y la estacionalidad entre destinos de turismo interior (Toledo), costa norte (San Sebastián), levante (Valencia) y sur (Málaga).

Analizar la información desestructurada extraída de las descripciones o títulos de los anuncios para identificar características de valor añadido y visualizar su impacto directo en el precio por noche.

2. Fuentes de Datos

Para la consecución de los objetivos, se usará una arquitectura de datos propia:

Web Scraping Avanzado: Se utilizará un conjunto de datos propio, actualmente en fase de recolección (con un volumen base superior a los 30.000 registros), generado mediante un *script* en Python que utiliza la librería `Playwright`. Este sistema realiza un barrido automatizado de plataformas de alquiler vacacional y consta de dos vías de extracción:

Extracción DOM: Captura de variables estructuradas directamente de la interfaz web (precio, camas, dormitorios).

Intercepción de Red: Captura de respuestas JSON asíncronas para extraer las coordenadas GPS exactas de cada inmueble, los identificadores únicos y fragmentos de texto desestructurado (títulos y descripciones).

La elección de un sistema de web scraping propio, en lugar de utilizar un conjunto de datos predefinido, se fundamenta en intentar construir una fuente de datos que pueda tener un gran

interés analítico, y que pueda ser utilizada a futuro, mientras cumpla estrictamente con los criterios de complejidad exigidos en la evaluación. Como garantía de viabilidad y prueba del criterio de "gran volumen" asociado al Big Data, el script desarrollado ya ha recopilado de forma exitosa una base superior a los 30.000 registros correspondientes a la ciudad de Toledo.

Para dotar al estudio de una mayor variedad de datos y de un profundo componente comparativo, el proceso de extracción se ampliará a 3 o 4 ciudades icónicas adicionales de la geografía española (como San Sebastián, Valencia y Málaga). Asimismo, se modificará la arquitectura del código para interceptar el tráfico de red asíncrono para capturar campos de texto libre (títulos y descripciones de los anuncios), integrando información de naturaleza desestructurada. Esta combinación de volumen, variedad geográfica y datos desestructurados conforma un conjunto de datos complejo, idóneo para su posterior tratamiento y visualización avanzada en Altair.

Apoyado por el motor de extracción automatizado, se compilará un conjunto de datos multidimensional para cada alojamiento. La captura se realizará iterando sobre distintas ventanas temporales (*snapshots*), evaluando el impacto de la anticipación de la reserva (*days_ahead*). El diccionario de datos constará de las siguientes dimensiones:

- **Variables Temporales y de Ocupación (Estructuradas):**
 - **Fecha de búsqueda y Fecha de *check-in*:** Para delimitar las ventanas de estudio (corto, medio y largo plazo).
 - **Antelación (*days_ahead*):** Días de diferencia entre la extracción y la fecha de disfrute.
 - **Huéspedes (*guests*):** Capacidad de ocupación configurada en la consulta.
- **Variables Físicas y Económicas (Estructuradas):**
 - **Precio (*price*):** Tarifa base por noche ofertada.
 - **Distribución física:** Número de camas (*beds*) y dormitorios (*bedrooms*).
 - **Identificador único (*id*):** Para la trazabilidad de los inmuebles a través de las distintas consultas.
- **Variables Geoespaciales:**
 - **Distancia al centro (*dist_centro_km*):** Cálculo algorítmico de la distancia exacta entre las coordenadas interceptadas del alojamiento y el punto céntrico de alto interés de la ciudad estudiada.
- **Características Cualitativas (Datos Desestructurados):**
 - **Textos descriptivos y títulos:** Cadenas de texto libre interceptadas del tráfico de red que albergan el título del anuncio y el resumen de características. De este campo desestructurado se procesarán y extraerán los servicios de valor añadido (p. ej., "con terraza", "vistas panorámicas", "piscina", "wifi"), lo que permitirá analizar su prima en el coste final.

3. Planificación

La planificación se ha ajustado al proceso de análisis de datos mediante visualización y a los hitos de entrega del curso académico.

Fase 1: Ampliación de la Extracción (2 de marzo - 22 de marzo) Adaptación del *script* actual (que ya opera sobre el mercado de Toledo) para iterar sobre las coordenadas centrales de San Sebastián, Valencia y Málaga. Se implementará la extracción del campo de texto descriptivo desde el interceptor de red para asegurar la recolección de datos desestructurados.

Fase 2: Preparación y Limpieza (23 de marzo - 12 de abril) Consolidación de los archivos CSV generados. Se realizará el tratamiento de valores nulos, la extracción de *features* clave a partir de los textos y la validación de las distancias calculadas. Esta fase culminará con la **Entrega Intermedia (13 de abril)** del conjunto de datos preparado, subido a la plataforma o repositorio en la nube.

Fase 3: Análisis Exploratorio y Visualización (14 de abril - 5 de mayo) Desarrollo de los gráficos definitivos empleando la librería Altair. Se priorizará la inclusión de elementos interactivos, tales como mapas de dispersión geoespacial y gráficos que muestren la evolución del precio (*days_ahead*).

Fase 4: Redacción de la Memoria y Empaquetado (6 de mayo - 14 de mayo) Elaboración de la memoria final (máximo 15 páginas) detallando el proceso de visualización y el análisis de los resultados.